

Investigación sobre codificación de caracteres y tipos de archivos

Codificación de Caracteres

La codificación de caracteres es el conjunto de reglas que permite a una computadora convertir texto (letras, números y símbolos) en formato binario (ceros y unos) para poder almacenarlo y procesarlo.

1. ASCII (American Standard Code for Information Interchange)

- **¿Qué es?:** Es uno de los estándares de codificación más antiguos (creado en 1963).
- **¿Cómo funciona?:** Utiliza 7 bits para representar cada carácter, lo que permite un total de 128 caracteres únicos (del 0 al 127). Incluye las letras del alfabeto inglés (mayúsculas y minúsculas), números del 0 al 9, signos de puntuación básicos y caracteres de control (como el salto de línea).
- **Limitación:** No incluye acentos (á, é), la letra "ñ", ni caracteres de otros idiomas. Por ello, hoy en día se usa casi exclusivamente como base para otros sistemas.

2. UTF-8 (Unicode Transformation Format - 8-bit)

- **¿Qué es?:** Es el sistema de codificación más utilizado en el mundo y el estándar indiscutible de la Web.
- **¿Cómo funciona?:** Es de longitud variable. Utiliza entre 1 y 4 bytes (8 a 32 bits) por carácter.
 - Si el texto está en inglés moderno, se comporta exactamente como ASCII (ocupa solo 1 byte por letra, ahorrando mucho espacio).
 - Si detecta caracteres especiales, acentos, emojis o caracteres asiáticos, expande automáticamente el tamaño a 2, 3 o 4 bytes para representarlos.
- **Ventaja:** Soporta prácticamente todos los caracteres e idiomas del planeta (es parte del estándar Unicode) y es sumamente eficiente en el uso de memoria para texto occidental.

3. UTF-16 (Unicode Transformation Format - 16-bit)

- **¿Qué es?:** Otra variante del estándar Unicode, diseñada para priorizar el acceso rápido a caracteres complejos.
- **¿Cómo funciona?:** También es de longitud variable, pero utiliza un mínimo de 2 bytes (16 bits) y un máximo de 4 bytes por carácter.
- **Diferencia clave con UTF-8:** Para el alfabeto inglés o texto web común, UTF-16 duplica el tamaño del archivo (porque usa mínimo 2 bytes donde UTF-8 usaría solo 1). Sin embargo, es muy eficiente para idiomas asiáticos (como el chino, japonés o coreano), ya que la mayoría de sus caracteres caben en los primeros 2 bytes. Es el sistema que utilizan internamente sistemas operativos como Windows y entornos como Java o .NET.

Tipos de Archivos para Almacenamiento y Transferencia de Datos

1. JSON (JavaScript Object Notation)

- **¿Qué es?:** Un formato ligero de intercambio de datos basado en texto plano. Aunque nació de JavaScript, hoy es completamente independiente del lenguaje.
- **Estructura:** Se organiza en pares de clave: valor y en listas (arrays), utilizando llaves {} y corchetes [].
- **Ventajas:** Es el formato estándar para las APIs web modernas debido a que es extremadamente fácil de leer y escribir por los humanos, y muy rápido de procesar (parsear) por las computadoras.

Ejemplo:

```
{  
  "partido": "LFDP",  
  "provincias": 10,  
  "activa": true  
}
```

2. XML (eXtensible Markup Language)

- **¿Qué es?:** Un lenguaje de marcado diseñado para almacenar y transportar datos, definiendo un conjunto de reglas para codificar documentos.
- **Estructura:** Utiliza etiquetas personalizadas encerradas en signos de menor y mayor que (<tag>contenido</tag>), muy similar a la estructura de HTML, organizando la información de forma jerárquica o en árbol.

- **Ventajas:** Es sumamente estricto, formal y permite validar la estructura del archivo mediante esquemas (XSD). Se utiliza mucho en sistemas empresariales antiguos, configuración de software pesado y para la facturación electrónica en muchos países.
- **Ejemplo:**

XML

```
<organizacion>
  <partido>LFDP</partido>
  <provincias>10</provincias>
</organizacion>
```

3. CSV (Comma-Separated Values)

- **¿Qué es?:** Un formato de texto plano extremadamente simple que se utiliza para almacenar datos en forma de tabla (filas y columnas). Su nombre correcto es CSV (con "S", por *Values*, aunque comúnmente se confunde el orden de las siglas).
- **Estructura:** Cada línea del archivo representa una fila de la tabla, y cada celda o columna está separada por un signo de puntuación (generalmente una coma , o un punto y coma ;). La primera fila suele contener los títulos de las columnas.
- **Ventajas:** Es el formato universal para exportar e importar datos entre hojas de cálculo (como Microsoft Excel o Google Sheets) y bases de datos debido a su nula complejidad y ligereza.
- **Ejemplo:**

Fragmento de código

```
Provincia,Region,Delegados
Distrito Nacional,Metropolitana,15
San Juan,Sur,8
Dajabon,Norte,5
```